

# Generative Adversarial Networks (GANs)


---

Advanced Institute for Artificial Intelligence – AI2

<https://advancedinstitute.ai>

# Função de ativação

Leaky Rectified Linear Unit, ou Leaky ReLU, é um tipo de função de ativação baseada em um ReLU, porém tem uma pequena inclinação para valores negativos. O coeficiente de inclinação é determinado antes do treinamento, ou seja, não é aprendido durante o treinamento. Este tipo de função de ativação é popular em tarefas nas quais podemos sofrer gradientes esparsos, ajudando a evitar que o gradiente fique "preso" em mínimos locais



## Funções Loss

- O Discriminador recebe as do conjunto de treinamento e do gerador (imagens falsas).
- Queremos que o discriminador seja capaz de distinguir entre imagens reais e falsas.
- Como as duas redes treinam ao mesmo tempo, as GANs também precisam de dois otimizadores. Cada um para minimizar as funções de perda do discriminador e do gerador, respectivamente. Queremos que o discriminador produza **probabilidades próximas de 1 para imagens reais e próximas de 0 para imagens falsas**. Para fazer isso, o discriminador precisa de duas perdas.
- Portanto, a **Loss total para o discriminador é a soma dessas duas perdas parciais. Uma para maximizar as probabilidades das imagens reais e outro para minimizar a probabilidade de imagens falsas**.

## Funções Loss

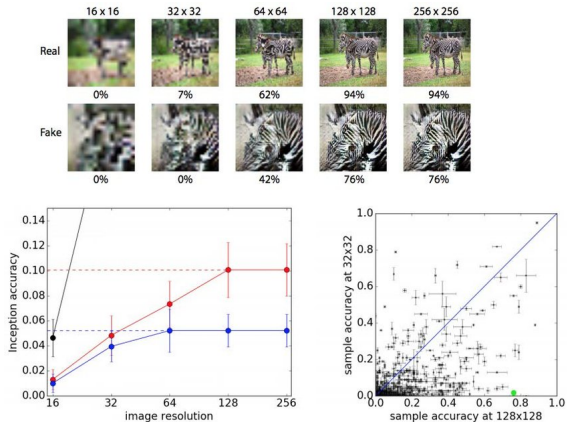
- No início do treinamento ocorrem duas situações: O gerador não sabe como criar imagens que se assemelham ao conjunto de treinamento e o discriminador não sabe como categorizar as imagens que recebe como reais ou falsas.
- Com isso, discriminador recebe dois tipos muito distintos de lotes: Um composto por imagens reais do conjunto de treinamento e outro contendo sinais ruidosos. Conforme o treinamento avança, o gerador começa a produzir imagens que se parecem mais com as imagens do conjunto de treinamento. Isso ocorre, pois o gerador treina para aprender a distribuição dos dados que compõem as imagens do conjunto de treinamento.
- Em paralelo, discriminador começa a se tornar bom em classificar amostras como reais ou falsas. Como consequência, os dois conjuntos começam a parecer estruturalmente semelhantes, fazendo com que o discriminador se torne incapaz de identificar quais imagens são reais ou falsas.

## Métricas de avaliação

- avaliar e comparar GANs continua sendo uma tarefa complexa, pois as características das imagens geradas afetam o resultado da métrica escolhida
- Não há consenso sobre qual métrica captura melhor os pontos fortes e as limitações dos modelos e quais devem ser usadas para uma comparação justa de modelos.
- Avaliar se as imagens geradas são visualmente semelhantes as reais X imagens geradas que preservam as características





# Inception Score (IS)

- O Inception score (IS) é uma forma popular de avaliar as imagens geradas por GANs.
- Utiliza um modelo pré-treinado com ImageNET, que possui muitas classes, tornando essa medida eficiente em avaliação de imagens realistas.
- Imagens mescladas (com diferentes classes) podem dificultar a avaliação
- Diferentes resoluções afetam a avaliação



# Fréchet Inception Distance (FID)

- FID é uma medida de similaridade entre dois conjuntos de dados de imagens.
- Se correlaciona bem com o julgamento humano da qualidade visual
- É frequentemente usado para avaliar a qualidade de amostras de GANs.
- O FID é calculado calculando a distância Fréchet entre dois Gaussianos ajustados
- CPU BOUND



Example of How Increased Distortion of an Image Correlates with High FID Score.  
Taken from: GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium.